

## Comparação de Duas Médias ou Proporções

2 de Setembro de 2020

### 0 Introdução

Ao longo destas notas de aula pensamos e discutimos os dois exemplos seguintes. É sugerido que o aluno reflita antes de ler as notas sobre como poderiam ser realizados experimentos para tentar responder a questões levantadas neles.

**Exemplo 1.** Uma locadora de carros possui uma grande frota de veículos todos da mesma marca, modelo e ano. Deseja testar dois tipos de combustíveis, digamos gasolina do tipo A e do tipo B, para saber qual deles oferece maior rendimento, medido como quilômetros/litro. Como poderíamos fazer um experimento para tentar responder essa pergunta?

**Exemplo 2.** Uma fábrica de calçados pode usar dois materiais, digamos A e B, para fazer as solas de um modelo de tênis. Os dois materiais têm custo semelhante e a empresa vai decidir usar aquele que tiver menos desgaste ao uso. A empresa quer testar os tênis em condições reais de uso. Para isso existe uma lista de filhos de funcionários da empresa que poderiam usar tênis do material A e do material B durante um período de tempo específico, ao fim do qual seria medido o desgaste como a diferença entre a espessura das solas antes e após o uso. Como poderíamos fazer um experimento para tentar responder essa pergunta?

### 1 Inferência para uma única população (Revisão)

A idéia central no problema de inferência para uma única média  $\mu$  estudada em PE1 pode ser descrita da seguinte forma: Suponha que queremos fazer inferência para um parâmetro  $\theta$  e que existe um estimador  $\hat{\theta} = \hat{\theta}(X_1, \dots, X_n)$ , cujo desvio padrão estimado (ou erro de estimacão)  $\hat{\sigma}_{\hat{\theta}}$  é tal que a distribuição (ou a distribuição limite quando  $n \rightarrow \infty$ ) de

$$\frac{\hat{\theta} - \theta}{\hat{\sigma}_{\hat{\theta}}} = \frac{\hat{\theta}(X_1, \dots, X_n) - \theta}{\hat{\sigma}_{\hat{\theta}}}$$

não depende dos parâmetros do modelo (no jargão estatístico, diz-se que essa quantidade é um *pivote* para  $\theta$ , no sentido que (i) a relação  $\theta \mapsto (\hat{\theta} - \theta)/\hat{\sigma}_{\hat{\theta}}$  é monótona e (ii) a sua distribuição não depende dos parâmetros do modelo). Nesse caso, usando a distribuição conhecida de  $(\hat{\theta} - \theta)/\hat{\sigma}_{\hat{\theta}}$ , podemos achar por exemplo valores  $a_I$  e  $a_S$  tais que

$$1 - \alpha = P \left( a_I \leq \frac{\hat{\theta} - \theta}{\hat{\sigma}_{\hat{\theta}}} \leq a_S \right) = P \left( \hat{\theta} - a_S \hat{\sigma}_{\hat{\theta}} \leq \theta \leq \hat{\theta} + a_I \hat{\sigma}_{\hat{\theta}} \right)$$

ou  $a_C$  tal que

$$\alpha = P \left( \frac{\hat{\theta} - \theta}{\hat{\sigma}_{\hat{\theta}}} > a_C \right).$$

A primeira dessas igualdades justifica usar o intervalo

$$\hat{\theta} - a_S \hat{\sigma}_{\hat{\theta}} \leq \theta \leq \hat{\theta} + a_I \hat{\sigma}_{\hat{\theta}}$$

como um *intervalo de confiança* (IC) de nível  $100(1 - \alpha)\%$  para  $\theta$ , enquanto a segunda justifica usar a região crítica

$$\frac{\hat{\theta} - \theta_0}{\hat{\sigma}_{\hat{\theta}}} > a_C$$

(equivalentemente,  $\hat{\theta} > \theta_0 + a_C \hat{\sigma}_{\hat{\theta}}$ ) para testar a  $H_a : \theta > \theta_0$

Revisamos então alguns dos ICs e testes estudados em PE1:

- **Distribuição Normal, variância conhecida:** Suponha que  $X_1, \dots, X_n$  é uma amostra aleatória da distribuição Normal com média  $\mu$  e variância **conhecida**  $\sigma_0^2$ . Nesse caso,  $\theta = \mu$ ,  $\hat{\theta} = \bar{X} = n^{-1} \sum_{i=1}^n X_i$ ,  $\hat{\sigma}_{\bar{X}} = \sigma_{\bar{X}} = \sqrt{\text{Var}(\bar{X})} = \sigma_0/\sqrt{n}$  e

$$\frac{\hat{\theta} - \theta}{\hat{\sigma}_{\hat{\theta}}} = \frac{\bar{X} - \mu}{\sigma_0/\sqrt{n}} = \sqrt{n} \frac{\bar{X} - \mu}{\sigma_0} \sim \text{Normal}(0, 1).$$

Podemos definir portanto  $a_I = -z_{\alpha/2}$ ,  $a_S = z_{\alpha/2}$  e  $a_C = z_\alpha$ , onde  $z_\alpha$  é o valor que deixa área ou probabilidade  $\alpha$  a sua direita na distribuição  $N(0,1)$  (para achar  $z_\alpha$ , usamos a tabela da Normal padrão ou, numa sessão do **R**, digite '`> qnorm(1-\alpha)`'). Assim, o IC acima fica

$$\bar{x} - z_{\alpha/2} \frac{\sigma_0}{\sqrt{n}} \leq \mu \leq \bar{x} + z_{\alpha/2} \frac{\sigma_0}{\sqrt{n}},$$

enquanto a região crítica para testar  $H_a : \mu > \mu_0$  é

$$z_{obs} = \sqrt{n} \frac{\bar{x} - \mu_0}{\sigma_0} > z_\alpha$$

ou, equivalentemente,  $\bar{x} \geq \mu_0 + z_\alpha \frac{\sigma_0}{\sqrt{n}}$ .

- **Qualquer distribuição,  $n$  grande:** Suponha que  $X_1, \dots, X_n$  é uma amostra aleatória de uma distribuição (qualquer uma!) com média  $\mu$  e **variância finita** desconhecidas, que  $n$  é grande (no jargão estatístico pensa-se que  $n \rightarrow \infty$ ). Então, se  $S^2 = (n-1)^{-1} \sum_{i=1}^n (X_i - \bar{X})^2$  é a variância da amostra, o Teorema Central do Limite (TCL) garante que a distribuição de  $\sqrt{n}(\bar{X} - \mu)/S$  é aproximadamente (no jargão estatístico, assintoticamente) Normal padrão. Logo, podemos tomar na formulação geral  $\theta = \mu$ ,  $\hat{\theta} = \bar{X}$ ,  $\hat{\sigma}_{\bar{X}} = S/\sqrt{n}$ ,

$$\frac{\hat{\theta} - \theta}{\hat{\sigma}_{\hat{\theta}}} = \frac{\bar{X} - \mu}{S/\sqrt{n}} = \sqrt{n} \frac{\bar{X} - \mu}{S} \stackrel{\text{aprox.}}{\sim} \text{Normal}(0, 1),$$

$a_I = -z_{\alpha/2}$ ,  $a_S = z_{\alpha/2}$  e  $a_C = z_\alpha$ . Assim, o IC acima (agora aproximado, ou assintótico) fica

$$\bar{x} - z_{\alpha/2} \frac{S}{\sqrt{n}} \leq \mu \leq \bar{x} + z_{\alpha/2} \frac{S}{\sqrt{n}},$$

enquanto a região crítica para testar  $H_a : \mu > \mu_0$  é

$$z_{obs} = \sqrt{n} \frac{\bar{x} - \mu_0}{S} > z_\alpha$$

ou, equivalentemente,  $\bar{x} \geq \mu_0 + z_\alpha \frac{S}{\sqrt{n}}$ .

- **Distribuição Normal, variância desconhecida:** Suponha que  $X_1, \dots, X_n$  é uma amostra aleatória de uma distribuição Normal com média  $\mu$  e variância  $\sigma^2$  desconhecidas. Então a quantidade  $\sqrt{n} \frac{\bar{X} - \mu}{S}$  segue a (assim chamada) distribuição  $t$  de Student com  $(n-1)$  graus de liberdade (gl). Portanto fazemos  $\theta = \mu$ ,  $\hat{\theta} = \hat{\mu} = \bar{X}$ ,  $\hat{\sigma}_{\bar{X}} = S/\sqrt{n}$ ,

$$\frac{\hat{\theta} - \theta}{\hat{\sigma}_{\hat{\theta}}} = \frac{\bar{X} - \mu}{S/\sqrt{n}} = \sqrt{n} \frac{\bar{X} - \mu}{S} \sim t_{n-1}$$

$a_I = -t_{n-1;\alpha/2}$ ,  $a_S = t_{n-1;\alpha/2}$  e  $a_C = t_{n-1;\alpha}$ , onde  $t_{n-1;\alpha}$  é o valor que deixa área ou probabilidade  $\alpha$  a sua direita na distribuição  $t$  com  $(n-1)$  gl (para achar  $t_{n-1;\alpha}$ , usamos a tabela da distribuição  $t$  de Student ou, numa sessão do R, digite ' $> qt(1-\alpha, n-1)$ '). Assim, o IC acima fica

$$\bar{x} - t_{n-1;\alpha/2} \frac{S}{\sqrt{n}} \leq \mu \leq \bar{x} + t_{n-1;\alpha/2} \frac{S}{\sqrt{n}},$$

enquanto a região crítica para testar  $H_a : \mu > \mu_0$  é

$$t_{obs} = \sqrt{n} \frac{\bar{x} - \mu_0}{S} > t_{n-1;\alpha}$$

ou, equivalentemente,  $\bar{x} \geq \mu_0 + t_{n-1;\alpha} \frac{S}{\sqrt{n}}$ .

- **Inferência para proporções,  $n$  grande:** Se  $X \sim \text{Binomial}(n,p)$  e  $\hat{p} = X/n$ , segue pelo Teorema de DeMoivre-Laplace (que é um caso particular do TCL) que, quando  $n \rightarrow \infty$ , a distribuição de

$$\frac{\hat{\theta} - \theta}{\hat{\sigma}_{\hat{\theta}}} = \frac{\hat{p} - p}{\sqrt{\hat{p}(1-\hat{p})/n}} = \sqrt{n} \frac{\hat{p} - p}{\sqrt{\hat{p}(1-\hat{p})}} \underset{\text{aprox.}}{\sim} \text{Normal}(0, 1) \quad (1)$$

ou, quando  $p = p_0$ ,

$$\frac{\hat{\theta} - \theta}{\hat{\sigma}_{\hat{\theta}}} = \frac{\hat{p} - p_0}{\sqrt{p_0(1-p_0)/n}} = \sqrt{n} \frac{\hat{p} - p_0}{\sqrt{p_0(1-p_0)}} \underset{\text{aprox.}}{\sim} \text{Normal}(0, 1),$$

Assim por um argumento semelhante ao feito nos outros casos, o IC com confiança aproximada  $100(1 - \alpha)\%$  para  $p$  é

$$\hat{p} \pm z_{\alpha/2} \sqrt{\frac{\hat{p}(1-\hat{p})}{n}}$$

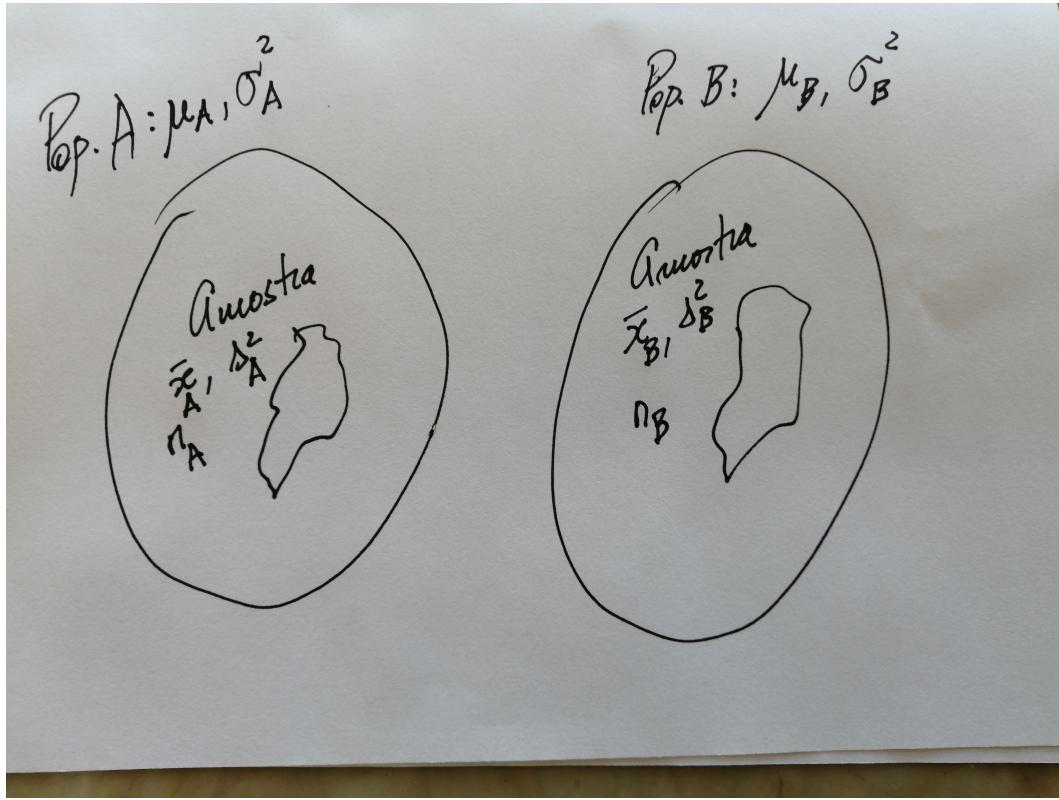


Figura 1: Amostras independentes.

e a região crítica para testar a  $H_a : p > p_0$  é

$$z_{obs} = \frac{\hat{p} - p_0}{\sqrt{p_0(1-p_0)/n}} > z_\alpha .$$

## 2 Comparação de duas médias: Amostras independentes

Considere duas populações  $A$  e  $B$ , cada uma delas com médias  $\mu_A$  e  $\mu_B$  e desvios padrões  $\sigma_A$  e  $\sigma_B$  respectivamente (veja a Figura 1). O problema é fazer inferência (estimar pontualmente, construir um IC ou testar se é maior, menor ou diferente do que um valor dado) sobre a diferença das médias, digamos  $\mu_B - \mu_A$ .

Como as médias populacionais  $\mu_A$  e  $\mu_B$  são desconhecidas, sabemos da Unidade 0 que elas podem ser estimadas a partir de amostras  $X_{A,1}, \dots, X_{A,n_A}$  da população  $A$  e  $X_{B,1}, \dots, X_{B,n_B}$  da população  $B$ . Usualmente, é fácil fazer com que o mecanismo amostral garanta que os valores observados na primeira amostra não influenciem os da segunda nem vice-versa e, nesse caso, dizemos que as amostras são *independentes* (eis o título desta Seção). Outra observação importante é que algumas vezes os dois tamanhos amostrais são iguais mas, como será visto mais adiante, pode ser conveniente que eles sejam diferentes, de forma que usamos símbolos diferentes  $n_A$  e  $n_B$ .

Uma vez que temos as duas amostras, sabemos da Unidade 0 que  $\bar{X}_A = n_A^{-1} \sum_{i=1}^{n_A} X_{A,i}$  é um estimador não-viesado para  $\mu_A$  (i.e. que  $E(\bar{X}_A) = \mu_A$ ) e que a sua variância é dada por  $\text{Var}(\bar{X}_A) = \sigma_A^2/n_A$ . De forma semelhante temos também que  $E(\bar{X}_B) = \mu_B$  e  $\text{Var}(\bar{X}_B) = \sigma_B^2/n_B$ . Devido a linearidade do operador *valor esperado*, segue que

$$E(\bar{X}_B - \bar{X}_A) = \mu_B - \mu_A.$$

Em outras palavras, se na notação usada na introdução definimos  $\theta = \mu_B - \mu_A$ , um bom candidato para estimá-lo é  $\hat{\theta} = \bar{X}_B - \bar{X}_A$ . Para avaliar o erro desse estimador precisamos calcular a sua variância, que é fácil lembrando que para quaisquer duas variáveis aleatórias  $X$  e  $Y$  com variâncias finitas tem-se que  $\text{Var}(aX+bY) = a^2 \text{Var}(X) + b^2 \text{Var}(Y) + 2ab \text{cov}(X, Y)$ , de forma que

$$\text{Var}(\bar{X}_B - \bar{X}_A) = \text{Var}(\bar{X}_B) + \text{Var}(\bar{X}_A) - 2 \text{cov}(\bar{X}_B, \bar{X}_A) = \frac{\sigma_A^2}{n_A} + \frac{\sigma_B^2}{n_B}, \quad (2)$$

onde temos usado o fato que  $\bar{X}_A$  e  $\bar{X}_B$  são independentes e, portanto, a sua covariância é nula.

A partir desse resultado, o maior problema que vai diferenciar as diferentes situações é como estimar a variância (2).

## 2.1 Populações normalmente distribuidas e variâncias conhecidas

O caso em que  $\sigma_A^2$  e  $\sigma_B^2$  são conhecidas é muito raro na prática, mas o seu estudo vai ajudar a entender melhor o resto da Seção. Veja que nesse caso não existe necessidade de estimar a variância (2). Se for ainda possível assumir que a distribuição das duas populações é Normal, sabemos da Unidade 0 que tanto  $\bar{X}_A$  quanto  $\bar{X}_B$  seguem distribuições normais e, como combinações lineares de variáveis aleatórias normais também são normais, segue que

$$\frac{\hat{\theta} - \theta}{\hat{\sigma}_{\hat{\theta}}} = \frac{\bar{X}_B - \bar{X}_A - (\mu_B - \mu_A)}{\sqrt{\frac{\sigma_A^2}{n_A} + \frac{\sigma_B^2}{n_B}}} \sim \text{Normal}(0, 1). \quad (3)$$

Com base nesse resultado, um IC de nível  $100(1 - \alpha)\%$  para a diferença  $\mu_B - \mu_A$  é

$$\bar{x}_B - \bar{x}_A \pm z_{\alpha/2} \sqrt{\frac{\sigma_A^2}{n_A} + \frac{\sigma_B^2}{n_B}},$$

onde  $z_{\alpha/2}$  é obtido da tabela da distribuição Normal Padrão. De forma semelhante, os testes de hipóteses sobre a diferença  $\mu_B - \mu_A$  são baseados no estatístico

$$z_{obs} = \frac{(\bar{x}_B - \bar{x}_A) - d_0}{\sqrt{\frac{\sigma_A^2}{n_A} + \frac{\sigma_B^2}{n_B}}}$$

onde  $d_0$  é o valor da diferença  $\mu_B - \mu_A$  especificado pela  $H_0$ . Mais precisamente,

- Para testar  $H_0 : \mu_B - \mu_A \leq d_0$  contra a  $H_a : \mu_B - \mu_A > d_0$  ao nível de significância  $100\alpha\%$ , rejeite  $H_0$  se  $z_{obs} > z_\alpha$ . O p-valor é  $P[N(0, 1) > z_{obs}]$ ;
- Para testar  $H_0 : \mu_B - \mu_A \geq d_0$  contra a  $H_a : \mu_B - \mu_A < d_0$  ao nível de significância  $100\alpha\%$ , rejeite  $H_0$  se  $z_{obs} < -z_\alpha$ . O p-valor é  $P[N(0, 1) < z_{obs}]$  e
- Para testar  $H_0 : \mu_B - \mu_A = d_0$  contra a  $H_a : \mu_B - \mu_A \neq d_0$  ao nível de significância  $100\alpha\%$ , rejeite  $H_0$  se  $|z_{obs}| > z_{\alpha/2}$ . O p-valor é  $P[|N(0, 1)| > |z_{obs}|]$ .

**Exemplo 1** (Continuação). A locadora abasteceu  $n_A = 20$  carros escolhidos aleatoriamente da sua frota com o combustível  $A$  e outros  $n_B = 20$  carros também escolhidos aleatoriamente com o combustível  $B$ . Todos os 40 carros realizaram depois um percurso predeterminado e ao final do percurso foi aferido o consumo para cada carro. Suponha que os carros grupo  $A$  tiveram consumo médio  $\bar{x}_A = 13.4\text{km/l}$ , enquanto a média do grupo  $B$  foi  $\bar{x}_B = 14.3$ . As refinarias que produzem os dois tipos de combustível informam que o desvio padrão do consumo para esse tipo de modelo é de  $1.5\text{km/l}$  para o combustível  $A$  e  $2.4\text{km/l}$  para o combustível  $B$ . Ao nível de significância de  $5\%$ , existe evidência que o combustível  $B$  é mais eficiente que o  $A$  para esse tipo de carros? Construa um IC com nível  $95\%$  para a diferença de consumo entre o combustível  $B$  e o  $A$ .

Para resolver, assumimos que a distribuição do consumo nos dois grupos é Normal. O desvio padrão (2) de  $\bar{X}_B - \bar{X}_A$  é  $\sigma_{\bar{X}_B - \bar{X}_A} = \sqrt{\frac{1.5^2}{20} + \frac{2.4^2}{20}} \doteq 0.633$ . Logo o IC para  $\mu_B - \mu_A$  é  $\bar{x}_B - \bar{x}_A \pm z_{\alpha/2} \sigma_{\bar{X}_B - \bar{X}_A} \doteq 14.3 - 13.4 \pm (1.96) 0.633 = (-0.340; 2.140)\text{km/l}$ . Para testar a hipótese alternativa  $H_a : \mu_B > \mu_A$  contra a nula  $H_0 : \mu_B \leq \mu_A$ , calculamos o estatístico do teste  $z_{obs} = (\bar{x}_B - \bar{x}_A)/\sigma_{\bar{X}_B - \bar{X}_A} \doteq (14.3 - 13.4)/0.633 \doteq 1.422$ . Como ele é menor que o valor crítico  $z_\alpha = z_{0.05} = 1.645$ , não rejeitamos a  $H_0$ , i.e. ao nível de  $5\%$  não existe evidência que o combustível  $B$  tem menor consumo (ou maior rendimento) do que o  $A$ . Para ter ideia da quantidade da evidência em favor da  $H_a$ , podemos calcular o p-valor do teste. Neste caso, como a  $H_a : \mu_B - \mu_A > 0$  é unilateral à direita, o p-valor é a área à direita do  $z_{obs} \doteq 1.422$  na curva Normal Padrão, isto é  $P[N(0, 1) > 1.422] \doteq 0.077$  ou  $7.7\%$ , que corresponde a evidência moderada contra  $H_0$  (por exemplo, a  $H_0$  seria rejeitada ao nível de significância de  $10\%$  mas, como vimos, não ao de  $5\%$ ).

**Para refletir:** No caso do exemplo, quais seriam as duas populações da Figura 1?  $\square$

## 2.2 Quaisquer populações e tamanhos amostrais grandes

Quando **os dois** tamanhos amostrais  $n_A$  e  $n_B$  são grandes, semelhante ao que ocorre para uma única população, tanto a distribuição de  $\bar{X}_A$  quanto a de  $\bar{X}_B$  são aproximadamente Normais e, portanto, também a da diferença  $\bar{X}_B - \bar{X}_A$ . A variância 2 pode ser estimada por

$$\hat{\sigma}_{\bar{X}_B - \bar{X}_A} = \sqrt{\frac{S_A^2}{n_A} + \frac{S_B^2}{n_B}},$$

onde  $S_A^2 = (n_A - 1)^{-1} \sum_{i=1}^{n_A} (X_{A,i} - \bar{X}_A)^2$  e  $S_B^2 = (n_B - 1)^{-1} \sum_{i=1}^{n_B} (X_{B,i} - \bar{X}_B)^2$  são as respectivas variâncias amostrais. Assim, temos nesse caso que

$$\frac{\hat{\theta} - \theta}{\hat{\sigma}_{\hat{\theta}}} = \frac{\bar{X}_B - \bar{X}_A - (\mu_B - \mu_A)}{\sqrt{\frac{S_A^2}{n_A} + \frac{S_B^2}{n_B}}} \stackrel{\text{aprox.}}{\sim} \text{Normal}(0, 1). \quad (4)$$

Com base nessa distribuição assintótica um IC aproximado de nível  $100(1 - \alpha)\%$  para  $\mu_B - \mu_A$  será

$$\bar{x}_B - \bar{x}_A \pm z_{\alpha/2} \sqrt{\frac{s_A^2}{n_A} + \frac{s_B^2}{n_B}},$$

onde  $z_{\alpha/2}$  é obtido da tabela da distribuição Normal Padrão. De forma semelhante, os testes de hipóteses são baseados no estatístico

$$z_{obs} = \frac{(\bar{x}_B - \bar{x}_A) - d_0}{\sqrt{\frac{s_A^2}{n_A} + \frac{s_B^2}{n_B}}},$$

onde  $d_0$  é o valor da diferença  $\mu_B - \mu_A$  especificado pela  $H_0$ . Mais precisamente,

- Para testar  $H_0 : \mu_B - \mu_A \leq d_0$  contra a  $H_a : \mu_B - \mu_A > d_0$  ao nível de significância  $100\alpha\%$ , rejeite  $H_0$  se  $z_{obs} > z_\alpha$ . O p-valor é  $P[N(0, 1) > z_{obs}]$ ;
- Para testar  $H_0 : \mu_B - \mu_A \geq d_0$  contra a  $H_a : \mu_B - \mu_A < d_0$  ao nível de significância  $100\alpha\%$ , rejeite  $H_0$  se  $z_{obs} < -z_\alpha$ . O p-valor é  $P[N(0, 1) < z_{obs}]$  e
- Para testar  $H_0 : \mu_B - \mu_A = d_0$  contra a  $H_a : \mu_B - \mu_A \neq d_0$  ao nível de significância  $100\alpha\%$ , rejeite  $H_0$  se  $|z_{obs}| > z_{\alpha/2}$ . O p-valor é  $P[|N(0, 1)| > |z_{obs}|]$ .

**Exemplo 1** (Continuação). Suponha que agora a locadora deseja comparar o consumo dos dois combustíveis num outro modelo/marca, para o qual as refinarias não fornecem informação sobre o desvio padrão do consumo (i.e. não conhecemos os valores de  $\sigma_A$  nem o de  $\sigma_B$ ). Como agora existe maior incerteza, a locadora abasteceu  $n_A = 40$  carros desse novo modelo, escolhidos aleatoriamente da sua frota, com o combustível  $A$  e outros  $n_B = 40$  carros, também escolhidos aleatoriamente com o combustível  $B$ . Todos os 40 carros realizaram depois um percurso predeterminado e ao final do percurso foi aferido o consumo para cada carro. Os carros do grupo  $A$  tiveram consumo médio  $\bar{x}_A = 9.4\text{km/l}$  e desvio padrão  $s_A = 1.8$ , enquanto para os do grupo  $B$  obteve-se  $\bar{x}_A = 10.5$  e  $s_B = 2.6$ . Construa um IC com nível 95% para a diferença de consumo entre o combustível  $B$  e o  $A$  e teste se o combustível  $B$  oferece menor consumo do que o  $A$  ao nível de significância de 5%

Veja que se aceitamos que  $n_A = 40$  e  $n_B = 40$  são suficientemente grandes para que, *via* o TCL, a aproximação 4 seja válida, não precisamos assumir mais nada para construir o IC aproximado. Esse IC para  $\mu_B - \mu_A$  é  $\bar{x}_B - \bar{x}_A \pm z_{\alpha/2} \sqrt{\frac{S_A^2}{n_A} + \frac{S_B^2}{n_B}} \doteq 10.5 - 9.4 \pm (1.96)(0.5) \doteq (0.120; 2.080)\text{km/l}$ .

Para testar a  $H_a : \mu_B > \mu_A$ , o estatístico do teste é  $z_{obs} = \frac{10.5 - 9.4}{\sqrt{\frac{1.8^2}{40} + \frac{2.6^2}{40}}} \doteq 2.200$ . Como ele é maior que o valor crítico  $z_{0.05} = 1.645$ , rejeitamos a  $H_0$ , i.e. ao nível de 5% existe evidência que o combustível  $B$  tem menor consumo do que o  $A$ .  $P[N(0,1) > 2.200] \doteq 0.014$  ou 1.4%, que corresponde a evidência forte contra  $H_0$ .  $\square$

### 2.3 Variâncias desconhecidas e tamanho amostral pequeno

Quando um ou os dois tamanhos amostrais  $n_A$  e/ou  $n_B$  são pequenos e as variâncias  $\sigma_A^2$  e  $\sigma_B^2$  são desconhecidas não podemos usar nenhum dos dois métodos discutidos acima. Nesse caso é comum assumir que (i) as duas populações são normalmente distribuídas [i.e.  $X_{A,1}, \dots, X_{A,n_A} \stackrel{iid}{\sim} \text{Normal}(\mu_A, \sigma_A^2)$  e  $X_{B,1}, \dots, X_{B,n_B} \stackrel{iid}{\sim} \text{Normal}(\mu_B, \sigma_B^2)$ ] e que as duas variâncias  $\sigma_A^2$  e  $\sigma_B^2$  são iguais, digamos  $\sigma_A^2 = \sigma_B^2 = \sigma^2$ . É claro que esses dois supostos restringem a aplicabilidade da metodologia que vamos a discutir. Embora uma ou as duas hipóteses podem ser retiradas, a comparação de médias no caso de tamanhos amostrais pequenos sem assumir normalidade e/ou igualdade das variâncias requer ferramental estatístico mais sofisticado que fica fora do escopo da disciplina, embora mais na frente nesta unidade vamos estudar o problema realizar testes de hipóteses para verificar se duas variâncias são iguais.

Como foi discutido acima, um problema fundamental fundamental é como estimar a variância (2) de  $\bar{X}_B - \bar{X}_A$ . Veja que como  $\sigma_A^2 = \sigma_B^2 = \sigma^2$ , a equação (2) fica agora

$$\text{Var}(\bar{X}_B - \bar{X}_A) = \frac{\sigma_A^2}{n_A} + \frac{\sigma_B^2}{n_B} = \sigma^2 \left( \frac{1}{n_A} + \frac{1}{n_B} \right), \quad (5)$$

de forma que estimar  $\text{Var}(\bar{X}_B - \bar{X}_A)$  é equivalente a estimar  $\sigma^2$ . Nesse sentido, poderíamos pensar em muitos estimadores de  $\sigma^2$ . Por exemplo, como a população  $A$  tem agora variância  $\sigma^2$ , um possível estimador é  $S_A^2 = (n_A - 1)^{-1} \sum_{i=1}^{n_A} (X_{A,i} - \bar{X}_A)^2$ . Da mesma forma,  $S_B^2 = (n_B - 1)^{-1} \sum_{i=1}^{n_B} (X_{B,i} - \bar{X}_B)^2$  também estima  $\sigma^2$ . Se tivéssemos que escolher entre um deles, escolheríamos possivelmente o da amostra com maior tamanho amostral, embora de certa forma estaríamos jogando fora a informação da outra amostra, pelo menos para estimar a variância comum  $\sigma^2$ . É possível mostrar então que o melhor estimador de  $\sigma^2$  não é nem  $S_A^2$  nem  $S_B^2$ , mas uma *média ponderada* deles de acordo ao número de graus de liberdade, isto é

$$S_c^2 = \frac{(n_A - 1) S_A^2 + (n_B - 1) S_B^2}{n_A + n_B - 2} \quad (6)$$

(o subíndice  $c$  é usado aqui no sentido de “estimador combinado”). Uma vez que temos esse estimador podemos substituir  $\sigma^2$  por  $S_c^2$  na equação (5) para obter um estimador de  $\text{Var}(\bar{X}_B - \bar{X}_A)$ . Depois disso, o resultado fundamental para construir ICs e regiões críticas de testes de hipóteses é que, sob o suposto de normalidade,

$$\frac{\bar{X}_B - \bar{X}_A - (\mu_B - \mu_A)}{\hat{\sigma}_{\bar{X}_B - \bar{X}_A}} = \frac{\bar{X}_B - \bar{X}_A - (\mu_B - \mu_A)}{S_c \sqrt{\frac{1}{n_A} + \frac{1}{n_B}}} \sim t_{n_A+n_B-2} \quad (7)$$

Consequentemente, o IC com nível de confiança  $100(1 - \alpha)\%$  será

$$\bar{x}_B - \bar{x}_A \pm t_{\alpha/2} s_c \sqrt{\frac{1}{n_A} + \frac{1}{n_B}},$$

onde  $t_{\alpha/2}$  é obtido da tabela da distribuição  $t$  de Student com  $(n_A + n_B - 2)$  graus de liberdade. De forma semelhante, os testes de hipóteses são baseados no estatístico

$$t_{obs} = \frac{(\bar{x}_B - \bar{x}_A) - d_0}{s_c \sqrt{\frac{1}{n_A} + \frac{1}{n_B}}},$$

onde  $d_0$  é o valor da diferença  $\mu_B - \mu_A$  especificado pela  $H_0$ . Mais precisamente,

- Para testar  $H_0 : \mu_B - \mu_A \leq d_0$  contra a  $H_a : \mu_B - \mu_A > d_0$  ao nível de significância  $100\alpha\%$ , rejeite  $H_0$  se  $t_{obs} > t_\alpha$ . O p-valor é  $P[t_{n_A+n_B-2} > t_{obs}]$ ;
- Para testar  $H_0 : \mu_B - \mu_A \geq d_0$  contra a  $H_a : \mu_B - \mu_A < d_0$  ao nível de significância  $100\alpha\%$ , rejeite  $H_0$  se  $t_{obs} < -t_\alpha$ . O p-valor é  $P[t_{n_A+n_B-2} < t_{obs}]$  e
- Para testar  $H_0 : \mu_B - \mu_A = d_0$  contra a  $H_a : \mu_B - \mu_A \neq d_0$  ao nível de significância  $100\alpha\%$ , rejeite  $H_0$  se  $|t_{obs}| > t_{\alpha/2}$ . O p-valor é  $P[|t_{n_A+n_B-2}| > |t_{obs}|]$ .

**Exemplo 1** (Continuação). Suponha que a locadora deseja comparar os dois combustíveis num outro modelo de carro com menor disponibilidade de unidades. Assim, foram alocados 20 carros para cada combustível. Durante o experimento um dos carros alocados ao grupo  $A$  quebrou e foi portanto retirado do estudo, de forma que temos efetivamente que  $n_A = 19$  e  $n_B = 20$ .

Suponha que os carros do grupo  $A$  tiveram consumo médio  $\bar{x}_A = 13.4\text{km/l}$  e desvio padrão  $s_A = 1.5$ , enquanto para os do grupo  $B$  obteve-se  $\bar{x}_A = 14.3$  e  $s_B = 2.4$ . Construa um IC com nível 95% para a diferença de consumo entre o combustível  $B$  e o  $A$ .

Para resolver, assumimos normalidade e variâncias iguais e calculamos primeiro  $s_c^2 = \frac{(19-1)(1.5)^2 + (20-1)(2.4)^2}{19+20-2} \doteq (2.013)^2$ . Logo, o IC para  $\mu_B - \mu_A$  é  $14.3 - 13.4 \pm (2.026)(2.013) \sqrt{\frac{1}{19} + \frac{1}{20}} = (-0.407; 2.207)\text{km/l}$ .

Veja que, embora os números são muito parecidos aos apresentados na Subseção 2.4, o IC aqui é mais comprido, o que é devido à maior incerteza devida ao desconhecimento das variâncias.

## 2.4 Uma nota sobre alocação amostral

Como foi notado no começo da Seção, é conveniente ter a flexibilidade de poder ter tamanhos amostrais diferentes nos dois grupos, i.e.  $n_A \neq n_B$ . Para fixar ideias, suponha como na Subseção 2.4 que as duas variâncias  $\sigma_A^2$  e  $\sigma_B^2$  são conhecidas. Como gostaríamos que a variância (2) seja pequena, de forma a obter, por exemplo, intervalos de confiança mais precisos, faria sentido alocar mais observações ao grupo onde a variância da população

é maior. Esta ideia pode ser formalizada como segue. Suponha que orçamento do experimento permite observar um total de  $n$  observações que podem ser alocadas a qualquer um dos dois grupos, de forma que temos uma restrição  $n_A + n_B = n$ . O objetivo é então minimizar a função  $f(n_A, n_B) = \frac{\sigma_A^2}{n_A} + \frac{\sigma_B^2}{n_B}$  sujeito a essa restrição. Falando estritamente, esse é um problema de programação inteira, pois obviamente as variáveis  $n_A$  e  $n_B$  podem tomar somente valores inteiros. Porém, podemos ter uma boa ideia da solução ótima procedendo como se  $n_A$  e  $n_B$  fossem variáveis reais. Nesse caso usando o método dos multiplicadores de Lagrange construímos a função  $f(n_A, n_B, \lambda) = \frac{\sigma_A^2}{n_A} + \frac{\sigma_B^2}{n_B} + \lambda(n - n_A - n_B)$  e igualamos a zero as suas derivadas parciais. É bastante fácil verificar que a solução ótima deve satisfazer que  $\frac{n_B}{n_A} = \frac{\sigma_B}{\sigma_A}$ . Se acrescentamos a restrição  $n_A + n_B = n$ , devemos ter então que

$$n_A = \frac{n}{1 + \sigma_B/\sigma_A} \quad \text{e} \quad n_B = \frac{n}{1 + \sigma_A/\sigma_B} \quad (8)$$

(verifique!) Note que esse resultado confere com a nossa intuição inicial: quanto maior é a variância de um grupo dado, com a outra fixa, maior será o tamanho alocado a esse grupo.

Os valores  $n_A$  e  $n_B$  na (8) não são necessariamente inteiros, de forma que é necessário arredondar esse resultado. Também, como na prática  $\sigma_A^2$  e  $\sigma_B^2$  não são conhecidas, para fazer a alocação amostral usam-se muitas vezes valores conjecturados por exemplo a partir de experimentos semelhantes realizados anteriormente ou, quando for possível, obtidos a partir de amostras piloto colhidas previamente do experimento principal.

**Exemplo 1** (Continuação). Na situação descrita na Subseção 2.4 ( $\sigma_A = 1.5$  e  $\sigma_B = 2.4$ ), quais seriam os tamanhos amostrais ótimos caso fosse possível observar somente 40 veículos?

Os tamanhos amostrais  $n_B$  e  $n_A$  devem estar na mesma relação que os desvios  $\sigma_B/\sigma_A = 2.4/1.5 = 1.6$ . Logo a equação (8) fornece  $n_A = 40/(1 + 1.6) \doteq 15.38$  e  $n_B = 40/(1 + 1/1.6) \doteq 24.615$ , que arredondamos para  $n_A = 15$  e  $n_B = 25$ . Verifique que, se tivessem sido usados esses valores de  $n_A$  e  $n_B$ , a variância (2) seria 0.617<sup>2</sup>, ligeiramente menor que o valor 0.633<sup>2</sup> que obtivemos com  $n_A = n_B = 20$ .  $\square$

Terminamos está seção notando que uma formulação um pouco mais geral deste problema permite introduzir custos por observação diferentes para os dois grupos. Mais precisamente, suponha que o experimento tem um orçamento  $\mathcal{O}$  fixo e custos por observação  $c_A$  e  $c_B$  para cada grupo, de forma que o problema é minimizar a variância (2) sujeito à restrição  $c_A n_A + c_B n_B = \mathcal{O}$ . A solução fica como exercício.

### 3 Comparação de duas médias: Amostras pareadas

No Exemplo 1 acima podemos nos perguntar o motivo da locadora escolher carros da mesma marca e modelo para realizar o experimento, ou determinar que cada carro realize o mesmo percurso predeterminado. A resposta tem a ver com as variabilidades medidas pelas variâncias  $\sigma_A^2$  e  $\sigma_B^2$ . Como tipicamente o rendimento de um tipo de combustível depende do tipo de veículo, se fossem usados veículos diferentes observaríamos

a variabilidade inerente ao combustível mas aquela devida ao tipo de veículo e/ou do percurso. Observando as fórmulas que usamos para construir os IC, vemos que maior variabilidade implica IC menos precisos (i.e. maior comprimento). Assim, o interesse do experimentador é controlar por todas aquelas variáveis que não dizem respeito ao fator que é o objetivo do experimento, que no caso da locadora tem a ver com os dois tipos de combustível.

Voltando agora ao Exemplo 2, a fábrica de sapatos poderia realizar o experimento de forma que as crianças “testadas” usassem cada uma um par de tênis fabricados com o material  $A$  ou com o material  $B$ . No final do experimento o desgaste poderia ser medido como a diferença média (para os dois pés, direito e esquerdo) entre a espessura das solas antes e após o uso, em cujo caso usaríamos as ferramentas apresentadas na Seção 3. Porém, realizar o experimento como *amostras independentes* faria com que a variabilidade inerente a cada material seria acumulada com a variabilidade devida por exemplo aos padrões de atividade das crianças (por exemplo, algumas podem praticar mais esporte enquanto outras podem ser mais sedentárias). Por isso, na situação do Exemplo 2, é tipicamente mais eficiente realizar o experimento de forma que cada criança usa num pé um tênis fabricado com o material  $A$  e no outro um fabricado com o material  $B$  e, ao final do experimento medir para cada criança a diferença de desgaste  $D_i$  entre o tênis do material  $B$  e o do material  $A$ . Dessa forma, boa parte da variabilidade devida às crianças será eliminada ao se fazer a diferença.

Observe que embora o título desta Seção é “amostras pareadas”, existe neste caso **somente** uma amostra, a das crianças, de forma que uma vez que as diferenças  $d_i$  são calculadas, usamos os mesmos métodos discutidos para uma única amostra na Seção 1. Em consequência, neste caso temos um único tamanho amostral  $n$ , ao invés da situação discutida na Seção anterior, onde tinha  $n_A$  e  $n_B$  que podiam ou não ser iguais.

Se no caso do Exemplo denotarmos por  $X_{A,i}$  e  $X_{B,i}$  os desgastes dos respectivos tênis e  $D_i = X_{B,i} - X_{A,i}$ , é verdade por causa da linearidade do operador *valor esperado* que  $E(D_i) = E(X_{B,i}) - E(X_{A,i}) = \mu_B - \mu_A$  (digamos, usando a notação da Seção 3), mas tipicamente esperamos que a variabilidade das diferenças  $D_i$  seja muito menor que a de  $X_{B,i}$  e que a de  $X_{A,i}$ , devido a que o padrão de atividade das crianças, por exemplo, fará que  $X_{A,i}$  e  $X_{B,i}$  sejam positivamente correlacionadas.

É importante apontar que certos experimentos são impossíveis ou muito difíceis de *parear*. Por exemplo, num estudo para comparar o efeito de dois tratamentos médicos, pode ser que o fator importante a ser controlado, além daquele inerente aos dois tratamentos ou drogas, seja a variabilidade genética dos pacientes. Uma forma de fazer esse controle seria parear os tratamentos para gêmeos idênticos. Porém, como esse tipo de gêmeos é relativamente raro, realizar um experimento pareado pode ser mais difícil do que realizá-lo em amostras independentes. Nesse caso, a opção é entre realizar um experimento pareado com  $n$  relativamente pequeno ou realizá-lo em amostras independentes com tamanhos  $n_A$  e  $n_B$  maiores, de forma que a comparação da eficiência das duas opções pode ser na prática mais complicada.

**Exemplo 2** (Continuação) A fábrica de sapatos escolheu  $n = 9$  crianças entre os filhos dos seus empregados e para cada um deles fabricou um par de tênis de forma que um dos

pés tinha a sola do material  $A$  e o outro do material  $B$  (qual pé recebeu qual material foi decidido ao acaso). Após 3 meses, os nove pares de tênis foram recolhidos e foi medido o desgaste em cada uma das 18 solas. As medidas do desgaste são dadas na tabela abaixo:

Criança										Média	DP
	1	2	3	4	5	6	7	8	9		
<b>A</b>	13.2	8.2	10.9	14.3	10.7	6.6	9.5	10.8	8.8	10.33	2.40
<b>B</b>	14.0	9.8	11.2	14.2	11.8	6.4	9.8	11.3	9.3	10.86	2.42
<b>B - A</b>	0.8	1.6	0.3	-0.1	1.1	-0.2	0.3	0.5	0.5	0.53	0.57

Construa um intervalo com confiança 90% para  $\mu_B - \mu_A$ . Ao nível de significância de 10%, existe evidência que o material  $A$  é mais resistente do que o  $B$ ? Calcule o p-valor.

Para resolver, usamos os resultados da Seção 1. Como o tamanho amostral é pequeno, precisaremos assumir que a distribuição das diferenças é Normal. Nesse caso, o IC é  $\bar{d} \pm t_{n-1; \alpha/2} \frac{s_d}{\sqrt{n}} = 0.53 \pm (1.860)(0.53/3) = (0.177; 0.883)$ , onde o valor  $t_{8,0.95} = 1.860$  é obtido da tabela da Distribuição  $t$  de Student com 8gl (ou, numa sessão do R, digitando  $> qt(0.95, 8)$ ). Para testar a  $H_a : \mu_d = \mu_B - \mu_A > 0$ , o estatístico do teste é  $t_{obs} = \sqrt{n} \bar{d} / s_d = 3(0.53)/(0.57) \doteq 2.789$ . Como ele é maior do que  $t_{8,0.90} = 1.397$ , rejeitamos a  $H_0$ , i.e. podemos afirmar que esses dados fornecem evidência suficiente para concluir ao nível de 10% que o material  $A$  é mais resistente em média do que o  $B$ . Finalmente, o p-valor desse teste é  $P(t_8 > t_{obs}) = P(t_8 > 2.789) = 0.012$  ou 1.2%.  $\square$

**Para refletir:** Seria possível realizar um experimento pareado no caso do Exemplo 1? Como?

## 4 Comparação de duas proporções

O interesse é fazer inferência sobre a diferença  $p_B - p_A$  das proporções ou probabilidades de uma certa característica para duas populações  $A$  e  $B$ . Se obtemos amostras aleatórias independentes com reposição de tamanhos  $n_A$  e  $n_B$  respectivamente, o número de indivíduos com a característica em estudo em cada amostra,  $X_A$  e  $X_B$ , seguem distribuições Binomiais com parâmetros  $n_A$  e  $p_A$  e  $n_B$  e  $p_B$  respectivamente.

Das propriedades da Distribuição Binomial sabemos que  $E(X_A) = n_A p_A$ , de forma que  $\hat{p}_A = \frac{X_A}{n_A}$  é um estimador não viesado para  $p_A$  e, analogamente,  $\hat{p}_B = \frac{X_B}{n_B}$  é um estimador não viesado para  $p_B$ . Logo, para estimar a diferença  $p_B - p_A$  usamos o estimador  $\hat{p}_B - \hat{p}_A$ . A variância desse estimador é

$$\text{Var}(\hat{p}_B - \hat{p}_A) = \text{Var}(\hat{p}_A) + \text{Var}(\hat{p}_B) = \frac{p_A(1-p_A)}{n_A} + \frac{p_B(1-p_B)}{n_B}, \quad (9)$$

onde usamos o fato que  $\hat{p}_A$  e  $\hat{p}_B$  são independentes e portanto a sua covariância é nula. Finalmente, quando  $n_A \rightarrow \infty$  e  $n_B \rightarrow \infty$ , pode-se mostrar que a distribuição limite do estimador é Normal ou, mais precisamente, que

$$\frac{\hat{p}_B - \hat{p}_A - (p_B - p_A)}{\sqrt{\frac{\hat{p}_A(1-\hat{p}_A)}{n_A} + \frac{\hat{p}_B(1-\hat{p}_B)}{n_B}}} \stackrel{\text{aprox.}}{\sim} \text{Normal}(0, 1).$$

Com esse resultado, quando  $n_A$  e  $n_B$  são grandes, o IC aproximado com nível  $100(1-\alpha)\%$  para  $p_B - p_A$  é

$$\hat{p}_B - \hat{p}_A \pm z_{\alpha/2} \sqrt{\frac{\hat{p}_A(1-\hat{p}_A)}{n_A} + \frac{\hat{p}_B(1-\hat{p}_B)}{n_B}}. \quad (10)$$

O problema para realizar testes de hipóteses para verificar se a diferença  $p_B - p_A$  é maior (menor, diferente) que um certo valor especificado  $d_0$  é mais complicado que no caso de diferença de médias. Abordamos aqui tão somente o caso que  $d_0 = 0$ , quando a hipótese nula específica que as duas proporções são iguais, digamos  $p_A = p_B = p$ . Veja que nesse caso a variância (9) fica

$$\text{Var}(\hat{p}_B - \hat{p}_A) = p(1-p) \left( \frac{1}{n_A} + \frac{1}{n_B} \right) \quad (11)$$

e, para estimá-la, devemos estimar o valor comum  $p$  de  $p_A$  e de  $p_B$ . É claro que  $p$  poderia ser estimado tanto por  $\hat{p}_A$  quanto por  $\hat{p}_B$  mas, de forma semelhante à discussão sobre a estimação de  $\sigma^2$  na Subseção 2.3, é possível obter um estimador mais preciso usando informação das duas amostras. A idéia principal é simples: quando  $p_A = p_B = p$ , podemos misturar as duas populações para ter uma única onde a proporção da característica em estudo. Portanto, as duas amostras de tamanho  $n_A$  e  $n_B$  podem ser pensadas como uma única amostra de tamanho  $n = n_A + n_B$  onde foram observados  $X = X_A + X_B$  indivíduos com a característica em estudo. Dessa forma, o estimador  $\hat{p}_c$  de  $p$  é

$$\hat{p}_c = \frac{X}{n} = \frac{X_A + X_B}{n_A + n_B} = \frac{n_A}{n_A + n_B} \frac{X_A}{n_A} + \frac{n_B}{n_A + n_B} \frac{X_B}{n_B} = \frac{n_A}{n_A + n_B} \hat{p}_A + \frac{n_B}{n_A + n_B} \hat{p}_B.$$

que é uma média ponderada dos estimadores originais  $\hat{p}_A$  e  $\hat{p}_B$  com pesos proporcionais aos respectivos tamanhos amostrais. Substituindo  $\hat{p}_c$  em (11) obtemos o estatístico do teste

$$z_{obs} = \frac{\hat{p}_B - \hat{p}_A}{\sqrt{\hat{p}_c(1-\hat{p}_c) \left( \frac{1}{n_A} + \frac{1}{n_B} \right)}}$$

Usando esse estatístico,

- Para testar  $H_0 : p_B - p_A \leq 0$  contra a  $H_a : p_B - p_A > 0$  ao nível de significância  $100\alpha\%$ , rejeite  $H_0$  se  $z_{obs} > z_\alpha$ . O p-valor é  $P[N(0,1) > z_{obs}]$ ;
- Para testar  $H_0 : p_B - p_A \geq 0$  contra a  $H_a : p_B - p_A < 0$  ao nível de significância  $100\alpha\%$ , rejeite  $H_0$  se  $z_{obs} < -z_\alpha$ . O p-valor é  $P[N(0,1) < z_{obs}]$  e
- Para testar  $H_0 : p_B - p_A = 0$  contra a  $H_a : p_B - p_A \neq 0$  ao nível de significância  $100\alpha\%$ , rejeite  $H_0$  se  $|z_{obs}| > z_{\alpha/2}$ . O p-valor é  $P[|N(0,1)| > |z_{obs}|]$ ;

**Exemplo 3.** Numa pesquisa eleitoral foram entrevistados 500 eleitores da cidade  $A$  e 400 da cidade  $B$ . Entre os eleitores da cidade  $A$ , 37% declararam a sua preferência pelo candidato NN, enquanto essa proporção foi de 42% na cidade  $B$ . Teste, ao nível de significância de 1%, se existe evidência no sentido que a preferência dos eleitores por NN

é diferente nas duas cidades. Calcule o p-valor do teste e construa um IC de nível 99% para a diferença.

Os tamanhos amostrais são suficientemente grandes para poder usar os métodos descritos acima. Para testar  $H_0 : p_B - p_A = 0$  contra a  $H_a : p_B - p_A \neq 0$ , calculamos primeiro  $\hat{p}_c = [(0.37)(500) + (0.42)(400)] / (500 + 400) \doteq 0.392$ . Logo, o estatístico do teste é  $z_{obs} \doteq (0.42 - 0.37) / \sqrt{(0.392)(1 - 0.392)(500^{-1} + 400^{-1})} \doteq 1.527$ . Como esse valor é (em valor absoluto) menor do que  $z_{0.005} \doteq 2.576$ , não rejeitamos a  $H_0$  (i.e. com esses dados não existe evidência suficiente para concluir que  $p_A \neq p_B$ ). O p-valor do teste é  $P[|N(0, 1)| > 1.527] \doteq 0.127$ , sinalizando que existe no máximo evidência fraca no sentido que as preferências nas duas cidades são diferentes. Finalmente, calculamos primeiro a variância estimada a partir da equação 9,  $\hat{\sigma}_{\hat{p}_B - \hat{p}_A} = \frac{(0.37)(1-0.37)}{500} + \frac{(0.42)(1-0.42)}{400} \doteq (0.033)^2$ , de forma que o IC (10) é  $0.42 - 0.37 \pm (2.576)(0.033) \doteq (-0.034; 0, 134)$ , i.e. com 99% de confiança podemos afirmar que a diferença entre a preferência por NN na cidade  $A$  e na cidade  $B$  está entre  $-3.4$  e  $+13.4\%$ .  $\square$